

문제 4 · 교란요인을 지우는 두 가지 방법

— 통제와 무작위화

Q1 → Q3, 펭귄 데이터

Q4 → Q5, 학생 데이터

통계 101 × 데이터 분석 · 10장 | 실습 문제 4

전체 흐름 : Q1 → Q5



전체로 보면

종별로 나누면


종을 통제하면

관찰만 하면


무작위로 배정하면

Q1~Q3 은 같은 펭귄 데이터를 다르게 보는 이야기,
Q4~Q5 는 같은 학생 데이터를 다르게 배정하는 이야기

상관과 인과



상관관계 — 방향 없이 함께 움직임



인과관계 — 원인이 결과를 만듦

상관은 “**함께 움직인다**”는 사실만 말해줄 뿐이지만, 인과는 “**원인을 바꾸면 결과도 바뀐다**”는 것까지 말해줍니다. 데이터 분석에서 이 둘을 구분하지 못하면, 상관관계만 보고 섣불리 개입(정책·처방·투자)을 결정하는 실수로 이어지기 쉽습니다.




허위상관 (Spurious Correlation)

- 인과는 없지만 상관은 있어서, 마치 인과가 있는 것처럼 보이는 경우
- 대부분 눈에 보이지 않는 제3의 원인, 즉 교란요인(Confounder)이 두 변수 모두에 영향

Q1

전체 데이터로 보면?

bill_depth_mm ~ bill_length_mm (342마리 전체)



기울기

-0.085

p-값: 1.1197e-05 ($p < 0.001$, 통계적으로 유의)


이 결과만 보면:

**"부리 길이가 길수록 부리 두께는 통계적으로 유의하게
얇아진다." 는 추론이 가능**

Q2

종별로 나누면?

Adelie · Chinstrap · Gentoo 각각 따로 회귀



종	n	기울기	p-값
Adelie	151	0.178834	6.67E-07
Chinstrap	68	0.222212	1.53E-09
Gentoo	123	0.204844	1.02E-15


세 종 모두

+0.18 ~ +0.22 $p < 0.001$ (세 종 모두 유의)

- 같은 종 -> "부리가 길수록 두껍다"는 게 일관된 관계
- 전체 종 -> 반대 방향의 가짜 관계(허위상관) 발견

심슨의 역설 (Simpson's Paradox)

각 부분(종별)에서는 A라는 관계가 성립하는데,
그 부분들을 모두 합쳐 전체로 보면 정반대인 B라는 관계로 뒤집혀 보이는 현상




Q3

종을 통제해서 한 번에?

$\text{bill_depth_mm} \sim \text{bill_length_mm} + \text{C}(\text{species})$

Q3 · 종을 통제한 회귀 (평행선)
기울기 = 0.200 (Q1: -0.085)



같은 기울기, 다른 절편 — '종'만큼 평행하게 이동

	종 고려 (Q1)	종 배제(Q3)
기울기	-0.08502	0.199894
p-값	0.000011	0
R ²	0.05525	0.768996

모델

R²

$\text{bill_depth_mm} \sim \text{bill_length_mm}$ (Q1)

0.055

$\text{bill_depth_mm} \sim \text{species}$ (종만, 길이 없이)

0.680

$\text{bill_depth_mm} \sim \text{bill_length_mm} + \text{species}$ (Q3)

0.769

- Q2(층별)와 Q3(다중회귀)는 같은 결론
- 종을 통제하니 부호가 다시 뒤집혀 Q2와 일치

교란요인을 지우는 방법 ① 통제

교란요인의 정체를 이미 알고 있다면(예: '성'), 그 효과를 통계적으로 제거하는 대표적인 방법이 존재

1. 층별 해석 (Q2)

- 층별요인 기준으로 데이터를 몇 개의 그룹(층)으로 나누고, 각 층 안에서만 관계를 따로 해석
- 층 안에서는 층별요인의 값이 거의 같으므로, 그 효과가 저절로 소멸

단점: 층이 많아질수록 층마다 표본 수가 줄어들어 추정이 불안정

2. 다중회귀 (조정) (Q3)

$$y = a + b_1 x + b_2 z$$

- 층을 나누는 대신, 교란요인 z 를 회귀식에 그대로 함께 넣어 한 번에 적합
- 편회귀계수 b_1 이 다른 변수의 영향을 제거한, x 의 순수한 인과효과를 증명

장점: 데이터 전체를 한 번에 사용하므로 표본이 줄어들지 않아 안정적

생각해볼 지점

- 두 방법 모두, '이름(존재)을 아는' 교란요인만 삭제 가능
- 만약 어떤 교란요인이 존재하는지조차 모른다면 어떻게 해야할지 고민이 필요

만약 교란요인의 이름을 모른다면?

인과추론의 근본 문제 (Fundamental Problem of Causal Inference)

한 학생이 강의를 들은 세계와 듣지 않은 세계를 동시에 관찰할 수는 없다.

즉 개인 수준의 인과효과는 원리상 알아낼 방법이 없다.

그래서 통계학은 개인이 아니라 집단 수준에서, 처치를 받은 집단과 받지 않은 집단의 '평균적인 차이(평균 처치효과)'를 측정

새로운 예시


학생 2,000명에게 새로운 온라인 강의를 개설했고,
이 강의의 참 효과는 기말고사 +5.0점이라고 가정합니다(우리가 추정해야 할 값).

같은 학생 2,000명에게, 강의를 배정하는 방식만 두 가지로 바꿔서 결과를 비교해 봅니다 → Q4 · Q5

Q4

관찰만 하면?

성적 좋고 열심히 학생이 스스로 신청 (관찰연구, df_obs)



단순 평균 차이

11.337점

참 효과 5.0점의 2배 이상

- 수강생은 비수강생보다 사전 성적이 평균 7.7점 높고, 주당 학습시간도 1.4시간 더 길다,
- 수강생 집단은 애초에 "강의를 듣지 않았어도 성적이 더 좋았을" 학생들로 구성돼 있어서, final_score 차이 11.337점 안에는 진짜 강의 효과(5.0점)와 원래 실력 차이(선택 편향, 약 6.3점)가 섞여 있는 것
=> **교란요인**
- 수강생은 강의를 듣기 전부터 이미 성적·학습시간이 더 높은 학생 - 강의 효과와 원래 실력 차이가 혼재
=> **선택 편향**

교란요인을 지우는 방법 ② 무작위화로 가기 전에



선택 편향 (Selection Bias)

- 스스로 처치를 선택한 집단은, 처치와 무관하게 이미 다른 특성을 갖고 있는 경우가 다수 존재
- (Q4 사례) 수강생은 강의를 듣기 전부터 이미 pre_score가 7.7점, study_hours가 1.4시간 더 높음
- 결과 차이에는 강의 효과와 원래 실력 차이가 혼재


그렇다면 어떻게 해야 두 집단을 '진짜로' 비슷하게 만들 수 있을까?

사람의 판단이나 특성이 끼어들 틈이 없도록, 아예 동전을 던져서 배정한다면 어떻게 될까?

Q5

동전을 던져 배정하면?

무작위 통제 실험 (RCT, df_rct) — 50% 확률로 배정



course	pre_score	study_hours	final_score
비수강생	59.903	10.237	70.262
수강생	59.974	10.229	75.242

단순 평균 차이

4.981점

참 효과 5.0점과 편향 -0.019

- 관찰연구는 수강생·비수강생 간 pre_score 차이가 7.687이나 됐지만, RCT는 0.071로 거의 0에 수렴
- 무작위로 배정했기 때문에 두 집단이 모든 면에서 통계적으로 동등, 그 결과 남는 차이는 오직 강의 효과뿐

왜 무작위화는 이렇게 강력한가

“중첩요인을 확인하지 않더라도, 그 효과를 무작위를 이용하여 무효화할 수 있으므로, 알고자 하는 변수의 효과만 추정 가능.”

- 동전을 던져 무작위로 배정하면, 이름을 아는 교란요인은 물론이고 이름조차 모르는 교란요인까지 두 집단에 통계적으로 고르게 분산
- Q5에서 pre_score와 study_hours가 저절로 균형
- 우리가 미처 생각하지 못한 다른 특성들도 마찬가지로 균형 -> 그래서 RCT(무작위 대조 시험)를 '인과추론의 황금 표준'으로 명명

하지만 언제나 가능한 것은 아니다

윤리적 문제 — 담배가 건강에 미치는 영향을 보려고 사람을 무작위로 흡연 집단에 배정하는 것은 불가

현실적 제약 — 최저임금 정책처럼 비용·시간·행정 절차 때문에 특정 지역에만 무작위로 적용하기 어려운 경우도 존재